変換前

Qwen3.8-27B

T テキスト

画像・動画

トークン埋め込み

視覚エンコーダー ×27

投影層

埋め込み列の統合

64層

GDN
FFN

GDN
FFN

GDN
FFN

全注意（Dense）
FFN

48 GDN + 16 Dense

×16

全注意（Dense）
全履歴のKVを保持

h

全トークンを参照

Q

注意計算

E

最終Norm

出力ヘッド
248,320

logits

MTP ×1
全注意（Dense）
FFN・共有出力ヘッド

反復

候補数は設定依存

埋め込み

採用・棄却

出力トークン

変換後

Qwen3.8-27B-QSA

T テキスト

画像・動画

トークン埋め込み

視覚エンコーダー ×27

投影層

埋め込み列の統合

64層

GDN
FFN

GDN
FFN

GDN
FFN

QSA
FFN

48 GDN + 16 QSA

×16

QSA注意
全履歴のKVを保持

h

Indexer
H4 · d128 · r4

最大512ブロック × 4

+ 自ブロック

Q

注意計算

16 indexers · +52.4M FP32

E

最終Norm

出力ヘッド
248,320

logits

MTP ×1
全注意（Dense）
FFN・共有出力ヘッド

反復

候補数は設定依存

埋め込み

採用・棄却

出力トークン

元の重みを維持　　追加学習　　専用実行系・MTP有効